

ANEXO:

1. **Antecedentes:** Este tema de tesis nace a partir del proyecto “Tactical Recipe” entre Accenture y Anglo American, en donde se buscaba mejorar la producción de la planta concentradora de cobre Los Bronces a través de la reducción de las caídas de toneladas procesadas por hora (TPH). Para esto se desarrolló un modelo estadístico que recomienda con cuanto material cargar el molino SAG de la planta. Esto se conoce como la recomendación de celda de carga.

Cuando participe en este proyecto mi rol fue mejorar el modelo ya existente y llevarlo a producción para dar las recomendaciones a la operación de manera online. En esa oportunidad mi rol no me permitió poder desarrollar mis propias ideas para generar el modelo prescriptivo que tenía en mente. Es así como todas mis ideas las quise plantear en mi tema de tesis de Magíster.

La idea consiste en desarrollar un simulador de escenarios operacionales a través de un modelo predictivo de TPH. En ese sentido en [1] se desarrolla un modelo predictivo del nivel de llenado de un molino SAG en función de sus presiones para luego usar esta estimación en la optimización del consumo energético.

Dado un contexto operacional definido por las propiedades mineralógicas del mineral y la granulometría del material entrante al molino SAG, se generarán diferentes escenarios a través de las variables manipulables con el objetivo de minimizar pérdidas. En la literatura, se menciona el concepto de “Digital Twin” [2] el cual hace referencia a un simulador del proceso con el mayor nivel de detalle posible. En el caso particular del molino SAG para poder llegar a hablar de un “Digital Twin” también sería necesario llegar a tener modelos que predigan el comportamiento de las acciones del sistema de control sobre sus variables controladas, como lo es la propia celda de carga, pero esto está fuera del scope del tema de tesis, ya que de por si es un tema demasiado amplio para explorar.

Según la literatura, para generar modelos prescriptivos, se puede utilizar “Reinforcement Learning”, el cual de hecho se puede combinar con “Digital Twins” [2]. Otros enfoques lo son el “Offline Reinforcement Learning” [4] el cual no necesita de un ambiente que simule interacciones, si no que en base a los mismos datos disponibles permite evaluar cual fue el mejor conjunto de acciones tomadas según la función objetivo definida. En el contexto del problema definido, “Reinforcement Learning” es descartado como una potencial solución debido a que no es claro como definir estados para representar la dinámica del proceso en cuestión, esto debido a que los tiempos de respuesta son prácticamente instantáneos. Finalmente, para la optimización de TPH en molinos SAG, también se puede encontrar el uso de algoritmos genéticos junto con ecuaciones físicas que describen el fenómeno [3].

En el caso particular de la solución propuesta, para generar recomendaciones, será de una manera relativamente sencilla, la cual consiste en proponer distinta señales candidatas a recomendar para luego ser procesadas mediante ingeniería de características y finalmente ingresar dichas características como input al modelo predictivo de TPH, para luego recomendar la señal que minimice las pérdidas de TPH.

En el contexto de sistemas recomendadores de acciones, también es importante definir métricas para poder medir la calidad de las recomendaciones que el modelo entrega, además, permite iterar en el desarrollo de modelos prescriptivos que den cada vez mejores recomendaciones de acciones [5][6][7].

Para el desarrollo de tesis, también es muy importante poder definir una métrica, ya que nos permitirá mostrar cuantitativamente que el nuevo modelo propuesto supera la calidad de las recomendaciones del modelo estadístico.

2. **Objetivos:**

1. **Objetivo general:** Diseñar y desarrollar sistema prescriptivo en molino SAG para la estabilización de la operación en función de recomendaciones de celda de carga.
2. **Objetivos específicos:**
 - i. Diseñar y desarrollar métrica de desempeño para comparar la calidad de las recomendaciones respecto a modelos ya existentes.
 - ii. Diseñar y desarrollar modelo predictivo de TPH.
 - iii. Diseñar y desarrollar modelo prescriptivo utilizando el modelo predictivo de TPH desarrollado.
 - iv. Evaluar modelos desarrollados, comparar y analizar resultados.

3. **Metodología:**


1. Generar entendimiento de la dinámica del proceso y el problema de negocio.
2. Desarrollar métrica de evaluación que represente la dinámica del proceso y el problema que se busca resolver.
3. Desarrollo de modelo predictivo de TPH en función de otras variables operaciones, tales como porcentaje de sólidos, rpm, celda de carga etc.
4. Se utilizará el modelo predictivo de TPH como un simulador de escenarios que permitirá simular las potenciales pérdidas de TPH. Con esto, se podrá recomendar como operar las variables manipulables del molino SAG que reducen de mejor manera las caídas de TPH.
5. A través de la métrica desarrollada se podrá evaluar el modelo existente y el nuevo modelo desarrollado, para luego comparar la calidad de la recomendación de los modelos y finalmente concluir cual es el modelo que genera las mejores recomendaciones para la operación.

4. **Plan de trabajo:** <https://1drv.ms/x/s!AqGmOmiZbUzLg78MCWivE7d2iNFxEg?e=ueNZ4K>

5. **Resultados esperados:** Los resultados esperados son desarrollar un modelo prescriptivo en base a técnicas de aprendizaje de máquinas que mejore la calidad de las recomendaciones del modelo estadístico actual. Como valor adicional, este enfoque permitirá a la operación poder visualizar una estimación futura de la señal de TPH, así como también la señal de TPH óptima que se tendría si se siguen las recomendaciones del nuevo modelo.

6. Referencias:

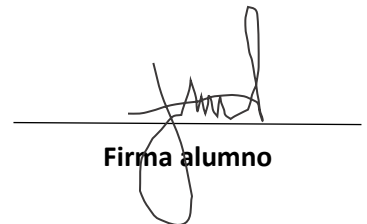
1. M. Curilem, G. Acuña, F. Cubillos, and E. Vyhmeister, "Neural networks and support vector machine models applied to energy consumption optimization in semiautogeneous grinding," vol. 25, pp. 761–766, 01 2011.
2. C. Cronrath, A. R. Aderiani, and B. Lennartson, "Enhancing digital twins through reinforcement learning," in 2019 IEEE 15th International Conference on Automation Science and Engineering (CASE), pp. 293–298, IEEE, 2019.
3. J. Becker, J. L. Salazar Navarrete, L. Magne, and F. Cubillos, "Real-time optimization of sag mills using genetic algorithms," 12 2022.
4. S. Levine, A. Kumar, G. Tucker, and J. Fu, "Offline reinforcement learning: Tutorial, review," and Perspectives on Open Problems, 2020.
5. G. Schröder, M. Thiele, and W. Lehner, "Setting goals and choosing metrics for recommender system evaluations," vol. 811, 01 2011.
6. P. Massa and P. Avesani, "Trust metrics in recommender systems," in Computing with social trust, pp. 259–285, Springer, 2009.
7. S. Vargas and P. Castells, "Rank and relevance in novelty and diversity metrics for recommender systems," in Proceedings of the fifth ACM conference on Recommender systems, pp. 109–116, 2011.



Firma profesor guía



Firma profesor co-guía



Firma alumno